

ÉTUDE

HISTOIRE DE L'INTELLIGENCE ARTIFICIELLE

De la Conférence de Dartmouth aux nouvelles perspectives neuro-symboliques

GRANDS THÈMES ABORDÉS

Origines — La Conférence de Dartmouth

Quatre trajectoires historiques — IA symbolique, IA connexionniste,
Apprentissage automatique, Traitement du Langage Naturel

Perspectives — Le pari du scaling et les architectures alternatives, le retour
du symbolique : hybridation ou fusion neuro-symbolique

Philippe LAURENS

Septembre 2026

« Je propose de remplacer la question "Les machines peuvent-elles penser ?" par une autre, qui lui est étroitement liée et qui s'exprime en des termes relativement sans ambiguïté. [...] La nouvelle forme du problème peut être décrite en termes d'un jeu que nous appellerons le "jeu de l'imitation". »

« La question initiale, "Les machines peuvent-elles penser ?", est selon moi trop insignifiante pour mériter une discussion. Néanmoins, je crois qu'à la fin du siècle, l'usage des mots et l'opinion générale des personnes instruites auront tellement changé que l'on pourra parler de machines qui pensent sans s'attendre à être contredit. »

Alan Turing, Computing Machinery and Intelligence (1950)

Warren McCulloch et Walter Pitts (1943) : Modélisation du neurone - Simple porte logique

Posent l'hypothèse que la pensée pourrait se ramener à du calcul.

Claude Shannon (1948) : Théorie de l'information

Séparation de l'information du sens : Peu importe ce que veut dire un message, seul comptent le coût de sa transmission et sa structure statistique.

Conférence de Dartmouth (1956)

L'été 1956 à Dartmouth est considéré comme l'acte de naissance officiel de l'intelligence artificielle en tant que champ de recherche autonome.

Dartmouth a été un lieu d'effervescence où les deux grands paradigmes de l'IA (symbolique et connexionniste/apprentissage) ont été posés côte à côte.


- **Le raisonnement symbolique** : Programmer l'intelligence en donnant à la machine des concepts clairs et des règles logiques explicites
 - Systèmes experts des années 1970-1980 (MYCIN pour le diagnostic médical),
 - Langage de programmation LISP et PROLOG.

Conséquence : Le raisonnement symbolique a connu un grand succès, puis un échec relatif face à la complexité du monde réel. Il fallait coder manuellement des milliers de règles, et le nombre de combinaisons possibles explosait.

- **Les réseaux de neurones** : Dartmouth a permis de discuter des réseaux de neurones et de les considérer comme l'un des axes de recherche prioritaires, avec notamment les travaux de Marvin Minsky (modèles neuronaux) et d'Oliver Selfridge (reconnaissance de formes).
 - Perceptron de Frank Rosenblatt (1958)

- **L'apprentissage** : Les organisateurs envisagent que la capacité d'apprendre puisse elle-même être programmée : non plus une règle fixée d'avance, mais un comportement qui s'ajuste au contact des données.
 - L'auto-correction par l'expérience :
 - Auto-amélioration (le programme modifie ses propres paramètres internes selon ses succès/ échecs, sans intervention humaine),
 - Apprentissage par renforcement rudimentaire (une forme primitive de récompense / punition guidant le comportement du programme)
 - Ces intuitions, sans lien direct avec les discussions de Dartmouth, trouveront leurs premières formalisations dans le champ statistique :
 - 1958, David Cox formalise la régression logistique pour la classification
 - 1967 : KNN (k-Nearest-Neighbors) est l'un des premiers algorithmes de reconnaissance de formes purement statistiques.

Convergence des paradigmes de l'IA



IA connexionniste

Question de la structure : comment modéliser le neurone et le réseau

IA par apprentissage

Question du comportement : comment la machine ajuste ses propres règles au contact de l'expérience

IA symbolique

Concepts clairs et des règles logiques explicites

Natural Language Processing (NLP)

La traduction automatique a d'abord emprunté au symbolique (règles grammaticales explicites dans les années 1950-1960), puis, des décennies plus tard, à l'apprentissage statistique (traduction automatique statistique dans les années 1990-2000), et au connexionniste (réseaux de neurones et transformers ensuite).

L'IA SYMBOLIQUE



LES RESEAUX DE NEURONES : DEEP LEARNING, LLMS



L'APPRENTISSAGE AUTOMATIQUE



LE TRAITEMENT DU LANGAGE NATUREL (NLP)




Compétition ImageNet (2012)

L'ImageNet Large Scale Visual Recognition Challenge (ILSVRC), lancée en 2010 : une base de données massive de plus d'un million d'images labellisées dans 1000 catégories. L'objectif de la compétition : une classification d'images avec le meilleur taux d'erreur.

En 2012, Alex Krizhevsky, étudiant de Hinton à Toronto, soumet AlexNet avec Ilya Sutskever et Hinton : Résultat, un écart de presque 11 points sur le second. Une synthèse d'ingrédients, combinés pour la première fois à cette échelle, produisent quelque chose de qualitativement différent :


- Architecture convolutive profonde : 8 couches apprenantes (5 conv + 3 fully connected), directement dans la lignée de LeCun, mais beaucoup plus grande.
- ReLU comme fonction d'activation : à la place de tanh/sigmoïde, ce qui accélère considérablement l'entraînement et atténue le vanishing gradient.
- Dropout : technique de régularisation qui éteint aléatoirement des neurones pendant l'entraînement, forçant le réseau à apprendre des représentations redondantes et robustes, réduisant l'overfitting.
- Data augmentation : transformations aléatoires des images (crops, flips) pour multiplier artificiellement les données d'entraînement.
- GPU : Krizhevsky entraîne le réseau sur deux GTX 580, ce qui rend computationnellement faisable ce qui ne l'était pas sur CPU. C'est peut-être l'élément le plus décisif dans l'immédiat : la puissance de calcul comme facteur de déblocage.



Entre 1986 et 2012, les conditions matérielles ont rattrapé les intuitions théoriques : les données (ImageNet), la puissance de calcul (GPU), et la profondeur des architectures ont convergé au bon moment. La théorie attendait l'infrastructure.

Attention is all you need (2017)

L'architecture transformers est divisée en deux parties distinctes, l'encodeur et le décodeur.




- **Embeddings / Tokens**

token : plus petite unité de texte traitée par un modèle.

embeddings : conversion de cet identifiant entier en un vecteur numérique à plusieurs dimensions

- **Le mécanisme d'attention** — La Self-Attention est l'idée générale selon laquelle les tokens portent attention les uns aux autres.
- La **Multi-Head Attention** est une extension du mécanisme d'attention dans les Transformers qui enrichit la Self-Attention.
- Le **Position-wise Feed-Forward Network (FFN)** prend la représentation de chaque mot, un par un et séparément, et la fait passer dans un petit réseau de neurones pour enrichir, digérer et approfondir ses informations, sans plus s'occuper des autres mots autour.

Une structure encodeur-décodeur




- **Encodeur uniquement (BERT)** — Conçu pour une compréhension bidirectionnelle, il traite les tokens d'entrée simultanément afin de capturer le contexte dans les deux directions. Utilisé pour des tâches comme la classification de texte, le question-réponse et les embeddings (BERT, RoBERTa). Il se concentre sur la modélisation de langage masqué (MLM), où certains tokens sont masqués et le modèle les prédit.
- **Décodeur uniquement (GPT)** — Autorégressif, il traite les tokens séquentiellement pour générer du texte, idéal pour des tâches comme la complétion de texte et le dialogue. Utilisé dans des modèles comme GPT-3, GPT-4 et de nombreux LLM propriétaires (parties de Claude ou LLaMA). Entraîné à la prédiction du token suivant, en se concentrant sur la modélisation de langage causale.
- **Encodeur-décodeur (T5)** — Combine un encodeur pour la compréhension de l'entrée et un décodeur pour la génération de la sortie, adapté à des tâches comme la traduction, le résumé et les transformations texte-vers-texte.

PERSPECTIVES

« Les prévisions nous en disent beaucoup sur ceux qui les font, elles ne vous disent rien sur l'avenir. »

Warren Buffett

La courbe de la hype sert à séparer le bruit médiatique de la maturité réelle d'une techno : où l'on survend, où l'on déchant, et où ça commence enfin à servir.



Gartner

Le Pari du scaling : plus de paramètres, plus de données, plus de calcul

Scaling Laws for Neural Language Models (Jared Kaplan, Sam McCandlish)

Training Compute-Optimal Large Language Models (Jordan Hoffmann) — Les lois de Chinchilla montre que la plupart des modèles étaient en réalité sur-paramétrés par rapport à leurs données

- Les grands labos observent des rendements décroissants du pur scaling en paramètres
- Ilya Sutskever (NeurIPS de décembre 2024) : compare les données d'internet à un combustible fossile en voie d'épuisement.

Problème : verrouillage d'infrastructure → ralentissement de l'adoption de solutions alternatives et innovantes

Architectures candidates à la relève

S4/Mamba (Gu) — Séquences longues en complexité linéaire, sans attention quadratique.

JEPA / World Models (LeCun) — Prédire dans un espace latent, pas token par token.

ARC / synthèse de programmes (Chollet) — Tester si un système invente une règle nouvelle à partir de peu d'exemples, au lieu de recourir à ce qu'il a déjà vu.

Apprentissage causal (Pearl, Bengio) — Structure causale plutôt que corrélation.

Forward-Forward / énergie libre (Hinton, Friston) — Autre règle d'apprentissage que la rétropropagation.

Les pionniers (Hinton, Bengio, LeCun), ont montré que l'apprentissage statistique à grande échelle marche ; ils doutent que ce soit toute l'intelligence : compréhension du monde (LeCun), structure causale et sûreté (Bengio), plausibilité biologique et risques (Hinton).

LeCun — Le langage est trop pauvre pour apprendre le monde. Un enfant voit autant de données qu'un LLM en lit, et il a gravité, objets, actions. Un modèle autoregressif continue un texte ; il n'a ni modèle du monde, ni planification. JEPA : prédire une représentation abstraite, pas le prochain token.

Bengio — Le scaling améliore le « système 1 » (association rapide). Il ne donne pas tout seul un « système 2 » (raisonnement, causalité, hors-distribution). Un LLM apprend ce qu'on dirait ; lui veut un modèle de ce qui est vrai, avec structure causale — d'où Pearl, représentations causales, plus récemment le « Scientist AI » (prédire le vrai plutôt que plaire). S'y ajoute une crainte de sûreté : des agents entraînés à optimiser un objectif dans le monde ne sont pas honnêtes par construction.

Hinton — Deux gestes distincts. 1) La rétropropagation marche, mais le cerveau ne semble pas l'utiliser (pas de passe arrière globale, pas de stockage de toutes les activations) : Forward-Forward teste une règle locale, deux passes avant. 2) Depuis 2023, il juge que des systèmes à l'échelle actuelle peuvent déjà devenir dangereux ; ce n'est pas un rejet du Deep Learning, c'est un rejet de l'insouciance.

IA Symbolique : hybridation ou fusion neuro-symbolique

Architecture neuro-symbolique — Toute architecture qui vient adosser au réseau de neurones une composante logique explicite, qu'elle s'y greffe de l'extérieur comme un garde-fou, ou s'y intègre au point de devenir un rouage du raisonnement lui-même.

Cause : hallucinations, absence de garanties logiques, raisonnement multi-étapes fragile

Hybridation (externe) — Lean : Assistant de preuve. Le mathématicien (ou le modèle) écrit une démonstration, un noyau formel la vérifie sans ambiguïté.

IA Agentique : Si un modèle a $X\%$ de fiabilité par étape, une tâche agentique de 20 étapes séquentielles tombe mécaniquement à environ $(X\%)^{20}$ de réussite globale.

Fusion neuro-symbolique (interne) — Il faudrait que le modèle puisse traiter n'importe quelle nouvelle combinaison de A et B jamais vue à l'identique, par composition, pas par ressemblance statistique avec des exemples proches

De la vérification à l'absorption : La vérification tend à être absorbée dans les poids du modèle lui-même par RL sur des tâches vérifiées. Le symbolique disparaît ainsi comme composant visible, sans que le problème de rigueur qu'il résolvait n'ait disparu pour autant.